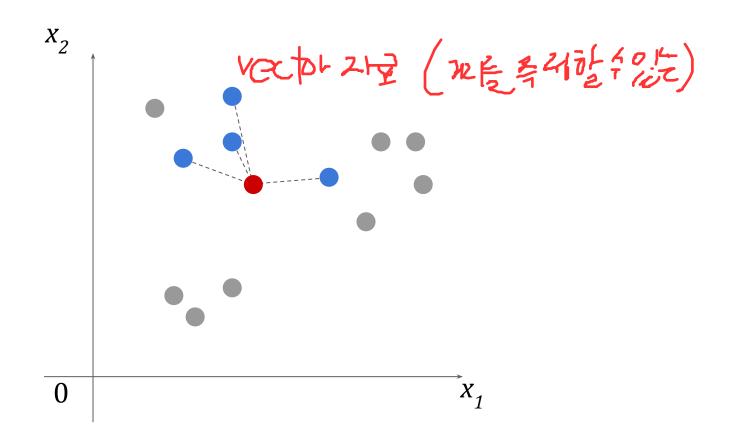
# 데이터과학

L11: K Nearest Neighbors

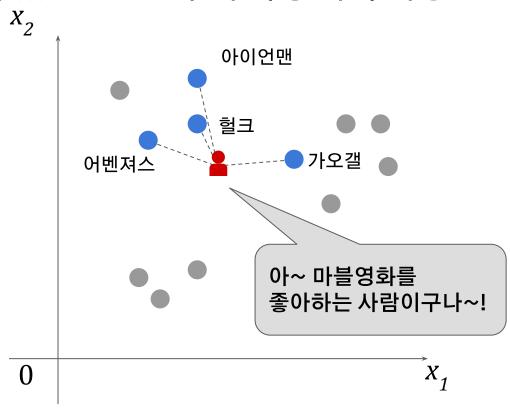
**Kookmin University** 

- k-Nearest Neighbors
- Choosing k
- Distances
- Pros and Cons of kNN
- Indexing for kNN

kNN = 가장 가까운 k개의 점



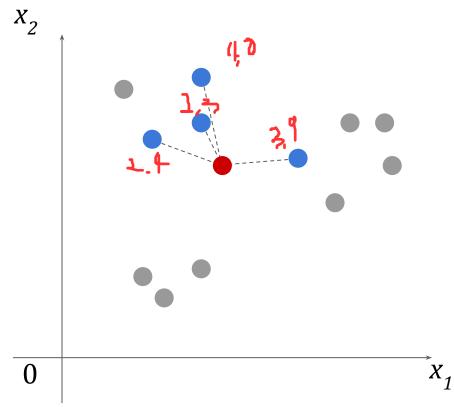
- 어떤 점의 특성을 알고 싶다면?
  - 가까이 있는 점으로부터 특성 파악 가능



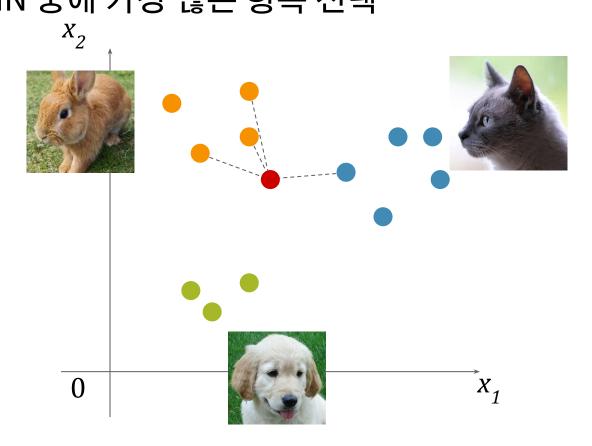
#### kNN의 특징

- 데이터 기반 분석 방법
- 데이터 분포를 가정하지 않음
- 회귀문제, 분류문제 등에 적용 가능

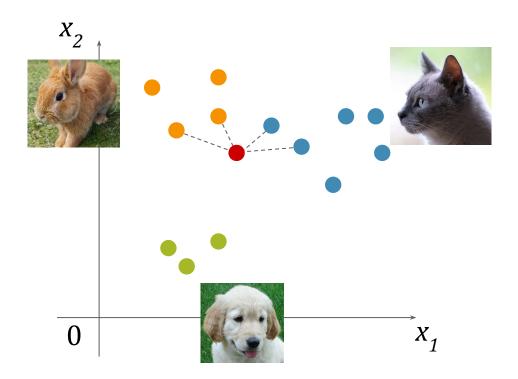
- kNN을 **회귀**문제에 적용 가능
  - kNN의 값을 평균 내어 값 예측



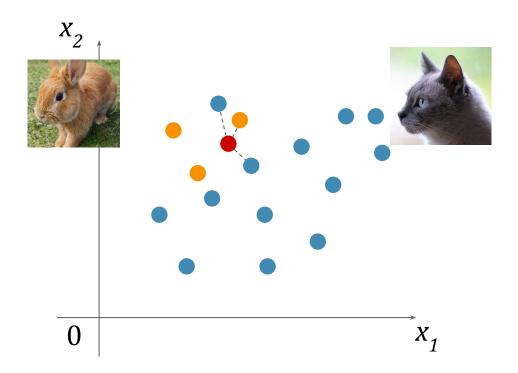
kNN을 분류문제에 적용 가능kNN 중에 가장 많은 항목 선택



- 1등이 여럿일 경우엔?
  - 방법1. 거리에 따라 가중치 주기
  - 방법2. 단독 1등이 나올 때까지 k를 하나씩 줄이기



- 데이터가 균일하지 않을 경우?
  - o cut-off를 조절

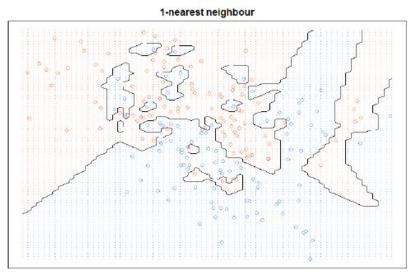


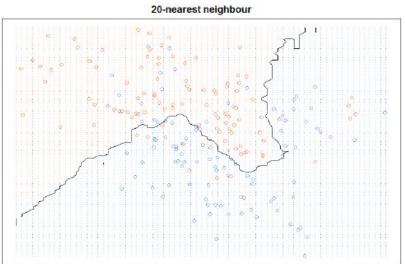
- k-Nearest Neighbors
- Choosing k
- Distances
- Pros and Cons of kNN
- Indexing for kNN

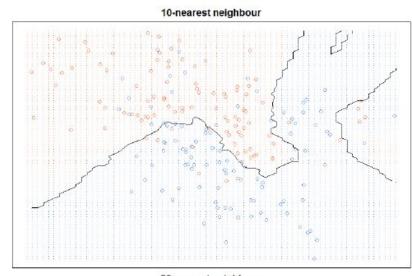
#### 적절한 k값은?

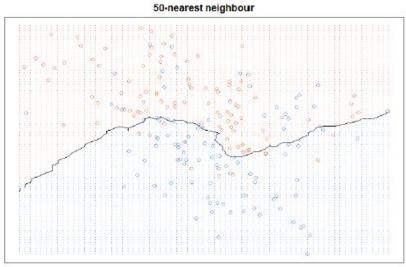
- / 데이터마다 적절한 k값이 다름
  - 。 k가 낮다 → 불안정한 결과 ~ 오버피팅
  - 。 k가 높다 → 지나친 일반화 ~ 언더피팅

# 적절한 k값은?









#### 적절한 k값은?

- k를 선택하는 방법: 가장 좋은 성능을 내는 값으로 선택
  - k의 값을 1부터 증가시켜가며 각 점들에 대해 knn으로 분류해보고 오류 계산
  - 가장 오류가 적은 k값을 선택

- k-Nearest Neighbors
- Choosing k
- Distances
- Pros and Cons of kNN
- Indexing for kNN

$$egin{align} X &= (x_1, x_2, \cdots, x_n) \ Y &= (x_1, x_2, \cdots, x_n) \ \end{pmatrix}$$

**Eucledian Distance (L2)** 

$$\sqrt{\sum_{i=1}^n \left(x_i-y_i
ight)^2}$$

Manhattan Distance (L1)



$$\sum_{i=1}^n |x_i-y_i|$$

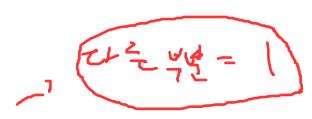
**Cosine Distance** 

• Cosine Distance 
$$1 - \frac{X \cdot Y}{|X||Y|} = \frac{X \cdot Y}{|X||Y|}$$

$$1-rac{X\cdot Y}{|X||Y|}$$



#### 거리?



Hamming Distance (곱집합)

$$|\{i \in \{1,2,\cdots,n\}| x_i 
eq y_i\}| egin{array}{c} X = (x_1,x_2,\cdots,x_n) \ Y = (y_1,y_2,\cdots,y_n) \end{array}$$

• 자카드거리 (집합)

$$1-rac{|X\cap Y|}{|X\cup Y|} ag{3.27} = \{x_1,x_2,\cdots,x_n\} \ Y=\{y_1,y_2,\cdots,y_m\}$$

#### 거리?

그 외...

- Standardized Euclidean Distance
- Mahalanobis Distance
- Correlation Distance

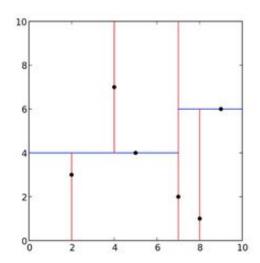
- k-Nearest Neighbors
- Choosing k
- Distances
- Pros and Cons of kNN
- Indexing for kNN

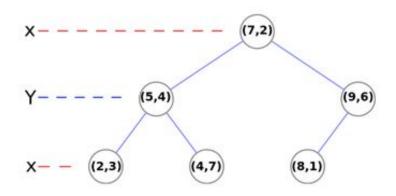
#### kNN 장단점

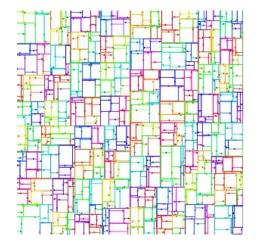
- 장점
  - 쉽고 이해하기 직관적
  - 사전 학습이 필요 없다
  - 어떤 분포든 상관 없음 (비모수 방식)
  - 데이터가 많을 경우 정확도 up! up! ✓
- 단점
  - 에이터가 많을 경우 연산량 up! up!
    - 한 차원 축소 등으로 계산량 감소이(성세설) 시
    - 인덱싱으로 탐색 속도 향상 R-Tree, KD-Tree, KNN-Graph, LSH(Locality Sensitive Hashing), etc.
  - 차원의 저주
    - 데이터의 차원이 증가함에 따라 정확도 급하락

- k-Nearest Neighbors
- Choosing k
- Distances
- Pros and Cons of kNN
- Indexing for kNN

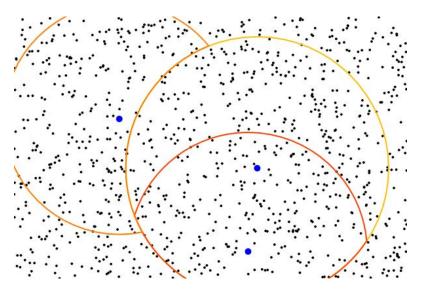
#### **KD-Tree**



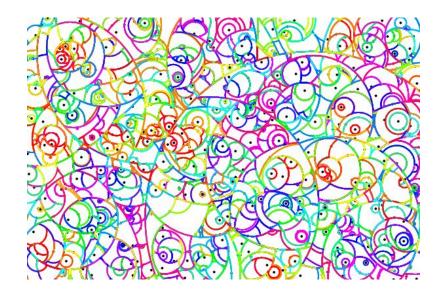




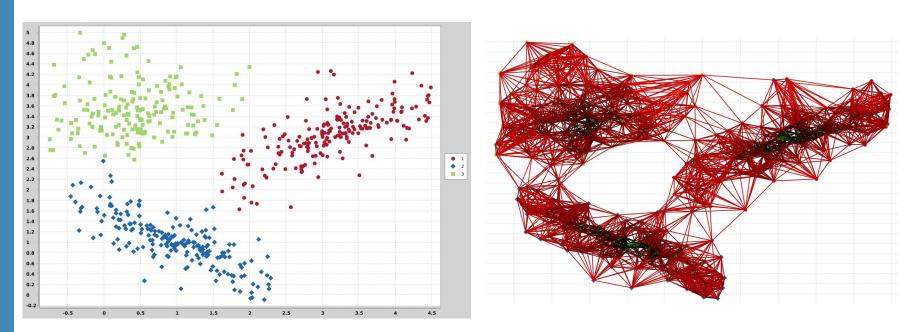
#### **VP-Tree**



출처: https://fribbels.github.io/vptree/writeup

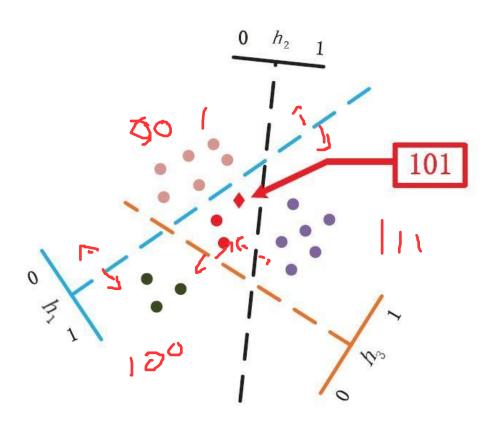


# KNN-Graph



출처: https://stats.stackexchange.com/a/187064

# **Locality Sensitive Hashing**



출처: Li, Haisheng, et al. "Feature matching of multi-view 3d models based on hash binary encoding." Neural Network World 27.1 (2017): 95.

P-tree

#### **Questions?**